

# 小目标检测调研报告

## 目录

- 1. 小目标的定义
- 2. 应用场景
- 3. 核心难点
- 4. 解决方案
- 5. 主流数据集与基准
- 6. 性能对比
- 7. 未来发展方向
- 8. 参考文献索引

## 1. 小目标的定义

### 1.1 COCO 绝对定义（业界主流标准）

MS COCO 数据集提出的定义是目前使用最广泛的标准，基于目标包围框的像素面积：

| 类别           | 像素面积                                        | 等效包围框边长         |
|--------------|---------------------------------------------|-----------------|
| 小目标 (Small)  | $< 32 \times 32$ (1024 px <sup>2</sup> )    | $< 32$ px       |
| 中目标 (Medium) | $32 \times 32 \sim 96 \times 96$            | $32 \sim 96$ px |
| 大目标 (Large)  | $\geq 96 \times 96$ (9216 px <sup>2</sup> ) | $\geq 96$ px    |

COCO 评估 API 中对应指标为 **AP<sub>S</sub>**（小目标平均精度），是衡量小目标检测能力的关键指标。

### 1.2 相对定义

部分研究者采用相对标准：

小目标：目标面积  $<$  图像总面积的 0.1%

该定义考虑了分辨率差异：4K 图像(3840×2160)中的"小目标"和 640×480 图像中的"小目标"在绝对像素上差异巨大。

### 1.3 领域特定定义

| 领域             | 定义标准                    | 说明         |
|----------------|-------------------------|------------|
| TinyPerson 数据集 | 目标高度 < 20 px，多数 < 10 px | 比 COCO 更严格 |
| 遥感/卫星图像        | 目标仅占数个像素                | 依赖传感器分辨率   |
| 工业缺陷检测         | 相对于产品表面的比例              | 无统一像素阈值    |
| 医学影像           | 相对于器官/组织区域的比例           | 依赖成像模态     |

### 1.4 定义的核心矛盾

- 绝对定义（COCO）
- 可比较、可量化，但不适应所有场景
- 相对定义（面积占比）
- 适应不同分辨率，但不够直观
- 领域特定定义
- 贴合实际，但缺乏通用性

结论：实践中通常以 COCO 定义为主，辅以领域特定定义

## 2. 应用场景

### 2.1 无人机 / 航拍检测

**最活跃的研究领域。**无人机在高空拍摄时，地面目标（车辆、行人）在图像中极其微小。

- 车辆与行人检测（高空俯视）
- 海事监控（小船、漂浮物）
- 搜救行动（失踪人员定位）
- 野生动物监测
- 城市规划与交通流分析

代表数据集：VisDrone、UAVDT、DOTA

## 2.2 自动驾驶

远距离的行人、交通标志、骑行者、路面障碍物在摄像头中仅占少量像素，但检测准确度直接关系安全。

距离 → 像素大小关系（以摄像头焦距  $f$  为例）：

物体宽度  $W$  在距离  $D$  处的像素数  $\approx f \times W / D$

行人(0.5m宽) 在 100m 外  $\approx$  仅 5~10 个像素

- 远距离行人检测
- 交通标志识别
- 路面异物预警
- 自行车道骑行者检测

## 2.3 医学影像

早期病灶、微钙化点等在影像中面积很小，但漏检后果严重。

- 早期肿瘤与病灶检测（乳腺癌、肺结节）
- 乳腺 X 光中的微钙化点
- 病理切片中的细胞分析
- 视网膜图像中的微动脉瘤
- 血液涂片中的异常细胞

## 2.4 工业缺陷检测

精密制造中，微小缺陷直接影响产品良率和安全性。

- 半导体晶圆表面微划痕
- 金属表面裂纹检测
- 电子元器件装配错误
- 纺织品瑕疵识别
- 3C 产品外观检测

## 2.5 安防监控

远距离监控场景下，可疑人员或物品在画面中尺寸极小。

- 周界入侵检测

- 人群密度估计
- 遗弃物检测
- 异常行为识别

## 2.6 精准农业

- 农作物病虫害检测（叶片上的微小病斑）
- 杂草识别
- 水果自动采摘定位
- 农作物生长状态监测

# 3. 核心难点

## 3.1 特征信息在下采样中丢失（最核心问题）

现代 CNN 通过池化层和步进卷积逐步降低空间分辨率。大目标在深层仍有足够像素，但小目标经多层下采样后可能**完全消失**。

示例：一个 16×16 像素的小目标在标准 ResNet 中的命运

```
输入：16 × 16
↓ conv1 (stride=2) → 8 × 8
↓ layer1 (stride=2) → 4 × 4
↓ layer2 (stride=2) → 2 × 2
↓ layer3 (stride=2) → 1 × 1    ← 仅剩 1 个像素
↓ layer4 (stride=2) → < 1 px  ← 目标完全消失
```

- 深层特征图中已无该目标的空间信息
- 无法进行有效的分类和定位

## 3.2 可用视觉信息有限

小目标先天包含的信息量不足：

| 信息维度 | 大目标 | 小目标  |
|------|-----|------|
| 纹理细节 | 丰富  | 几乎没有 |

| 信息维度  | 大目标 | 小目标 |
|-------|-----|-----|
| 形状信息  | 清晰  | 模糊  |
| 颜色梯度  | 明显  | 微弱  |
| 抗噪声能力 | 强   | 极弱  |
| 压缩鲁棒性 | 高   | 低   |

### 3.3 尺度变化剧烈

同一场景中可能同时存在极小和极大的目标，单一特征金字塔层级无法兼顾。

同一张航拍图像中：

- 远处车辆：5 × 5 px
- 近处建筑：500 × 500 px
- 尺度差异：100 倍

- 特征融合时小目标特征容易被大目标特征淹没
- 需要多尺度策略同时处理

### 3.4 信噪比低

小目标像素少，外观容易与背景纹理、传感器噪声、压缩伪影混淆，导致**高误检率**和**高漏检率**。

### 3.5 正负样本严重不均衡

背景像素数量远超小目标像素。以 640×640 图像中一个 16×16 的小目标为例：

- 目标像素：16 × 16 = 256
- 背景像素：640 × 640 - 256 = 409,344
- 正负比：1 : 1600（仅计算像素级）

- 训练时小目标的梯度贡献被背景淹没

### 3.6 Anchor 匹配困难

标准 Anchor 设计对极小目标的匹配问题：

- 常用 Anchor 最小尺寸为 8~16 px，小目标可能仅 4~10 px

- 即使轻微偏移也会导致 IoU 大幅下降，训练信号极弱
- 锚框与极小目标的匹配率低，导致正样本不足

## 3.7 密集遮挡问题

在密集场景中，小目标经常被其他目标部分遮挡：

- 航拍中的密集车辆
- 人群中的个体
- 医学影像中的重叠细胞

即使只被遮挡少量像素，对小目标的影响也极为严重（因为总像素本就不多）。


## 3.8 标注困难

人工标注小目标：

- 劳动强度大
- 标注误差比例高（几像素偏移就是很大的相对误差）
- 标注一致性差（不同标注者对同一目标的边界框差异大）

# 3.9 难点总结

根本原因：像素少 → 信息少




# 4. 解决方案

## 4.1 多尺度特征学习与融合

### 4.1.1 特征金字塔网络 (FPN) 及改进

FPN 基础架构：



# 4. 解决方案

## 4.1 多尺度特征学习与融合

### 4.1.1 特征金字塔网络 (FPN) 及改进

#### FPN 基础架构：

FPN 改进方法对比：

| 方法                      | 核心改进                 | 特点                           |
|-------------------------|----------------------|------------------------------|
| FPN (2017)              | 自顶向下 + 横向连接          | 基线方案                         |
| BiFPN<br>(EfficientDet) | 双向跨尺度连接 +<br>可学习加权融合 | 迭代精炼，信息流动更充分                 |
| HR-FPN                  | 高分辨率特征保持             | 避免特征冗余，提升小尺度精度               |
| D-FPN                   | 细节特征金字塔（航拍场景）        | 专门保留细粒度细节                    |
| EG-FPN                  | 边缘引导特征金字塔            | 融合边缘信息辅助定位                   |
| CFPT                    | 跨层特征金字塔 Transformer  | 无需上采样器，用 Transformer<br>跨层融合 |
| IFPN                    | 交互式特征金字塔             | 全局上下文信息增强                    |
| SEMA-YOLO               | 增强浅层特征 + 多尺度适应模块     | 轻量化设计                        |

BiFPN 加权融合示意：

```
# 标准FPN: P_out = P_in + Resize(P_higher)
# BiFPN:   P_out = w1*P_in + w2*Resize(P_higher) + w3*Resize(P_lower)
#           权重 w1, w2, w3 可学习，快速归一化

O = Σ(w_i * I_i) / (Σw_i + ε)  # 快速归一化融合
```

### 4.1.2 增加 P2 检测层

这是 YOLO 系列提升小目标检测最有效的单一架构改动。



标准 YOLO 检测头: P3 (80×80) → P4 (40×40) → P5 (20×20)  
↓ 对小目标不友好

增加 P2 层后: P2 (160×160) → P3 (80×80) → P4 (40×40) → P5 (20×20)  
↑  
高分辨率特征图, 保留更多小目标信息  
代价: 计算量增加 (Anchor 数量翻倍)

## 4.2 注意力机制

### 4.2.1 注意力类型与适用场景

| 注意力类型   | 代表模块              | 作用            | 适用场景     |
|---------|-------------------|---------------|----------|
| 通道注意力   | SE-Block          | 重标定特征通道权重     | 通用增强     |
| 空间注意力   | CBAM-Spatial      | 关注"在哪里"       | 小目标位置不固定 |
| 通道+空间   | CBAM              | 同时关注"什么"和"哪里" | 综合提升     |
| 自注意力    | Transformer       | 全局依赖建模        | 需要全局上下文  |
| 高斯注意力   | MGA-Net           | 多尺度高斯注意力      | 小目标精准定位  |
| 十字窗口注意力 | CSWin Transformer | 十字形窗口高效自注意力   | UAV 实时检测 |

### 4.2.2 混合 CNN-Transformer 架构

当前最实用的策略: CNN 提取局部特征 + Transformer 建模全局上下文。

输入图像  
↓  
CNN Backbone (局部特征, 保留空间细节)  
↓  
Transformer Encoder (全局上下文建模)  
↓  
多尺度检测头

- 优势:
- CNN 的归纳偏置有利于小目标的局部纹理提取
  - Transformer 的全局注意力帮助区分小目标和背景噪声

具体模型:

| 模型        | 架构设计                         | 亮点               |
|-----------|------------------------------|------------------|
| PARE-YOLO | YOLO backbone + RT-DETR head | 无 Anchor、无 NMS   |
| HSF-DETR  | 多视角上下文块 + 多尺度路径聚合            | UAV 场景高效检测       |
| ACD-DETR  | 基于 RT-DETR + 多尺度边缘增强         | 精细边界信息捕获         |
| AUHF-DETR | MobileNetV3 + 轻量 Transformer | 仅 5.8M 参数，68 FPS |

## 4.3 超分辨率增强

在检测前先提升图像分辨率，增加小目标的像素数量。

### 4.3.1 流程

低分辨率输入 → 超分辨率模型 → 高分辨率图像 → 目标检测器 → 检测结果

### 4.3.2 方法分类

| 方法     | 说明                   | 优缺点        |
|--------|----------------------|------------|
| GAN 超分 | 用 SRGAN/ESRGAN 恢复细节  | 效果好，但推理慢   |
| 扩散模型超分 | 用 Diffusion 模型生成高频细节 | 质量最高，速度最慢  |
| 轻量超分模块 | 嵌入检测网络内部的 SR 模块      | 端到端训练，速度更快 |
| 特征级超分  | 在特征空间而非像素空间做超分       | 计算量更小      |

### 4.3.3 注意事项

- 超分辨率 ≠ 一定提升检测性能
- 可能引入伪细节（幻觉），干扰检测
  - 推理开销显著增加
  - 需要端到端联合训练以对齐目标
  - 推荐仅在输入分辨率极低时使用

## 4.4 上下文信息利用

小目标自身信息不足，需借助周围环境辅助判断。

4.4.1 上下文类型

局部上下文：目标周围的纹理、边缘信息  
→ 帮助确定目标边界

场景上下文：目标所在场景的语义信息  
→ "路上很可能是车" "天空很可能是鸟"

目标间上下文：目标之间的空间关系  
→ "有车的地方附近可能有行人"

4.4.2 上下文建模方法

| 方法    | 机制                  | 适用场景    |
|-------|---------------------|---------|
| 扩大感受野 | 空洞卷积 (Dilated Conv) | 无需增加参数  |
| 上下文模块 | 专用上下文编码器            | 精确建模    |
| 场景先验  | 场景分类 + 目标检测联合       | 场景明确的任务 |
| 图模型   | 目标间关系建模             | 密集小目标   |

4.5 数据增强策略

4.5.1 针对小目标的增强方法

Mosaic 增强（YOLO 系列标配）：

将 4 张训练图拼接为 1 张：

|      |      |
|------|------|
| 图 A  | 图 B  |
| (缩放) | (缩放) |
| 图 C  | 图 D  |
| (缩放) | (缩放) |

- 效果：
- 小目标在不同上下文中出现 → 增强鲁棒性
  - Batch 大小等效翻 4 倍 → 训练更稳定
  - 背景多样性增加

Copy-Paste 增强：

- 1. 从源图像中裁剪小目标实例（使用已有标注）
- 2. 对实例做随机变换（缩放 0.8~1.2、翻转、色彩抖动）
- 3. 粘贴到目标图像的合理位置
- 4. 更新标注信息
- 5. 可选：边缘模糊 / 混合使粘贴更自然

关键：粘贴位置应符合语义（如车应贴在路上）

SAHI（切片辅助推理）：

训练阶段（Slicing Aided Fine-tuning, SF）：

- 1. 将大图切分为重叠的小图块
- 2. 每个图块中原本很小的目标相对变大
- 3. 在切片上训练检测器

推理阶段：

- 1. 输入大图 → 切分为重叠图块
- 2. 每个图块独立检测
- 3. 合并检测结果（去重 + NMS）

优势：显著提升小目标 AP\_S

劣势：推理时间增加 N 倍（N 为切片数）

4.5.2 生成式数据增强

| 方法                  | 说明               |
|---------------------|------------------|
| AeroGen (CVPR 2025) | 扩散模型生成遥感小目标数据    |
| GAN 生成              | 生成少数类/小目标合成样本    |
| 概念感知生成增强            | 在语义层面引导生成，超越传统增强 |

# 4.6 训练分辨率提升

标准训练分辨率：640 × 640  
小目标推荐分辨率：1280 × 1280 或更高

- 效果：
- 小目标的像素数量翻 4 倍
  - 特征提取更充分
  - AP\_S 显著提升

- 代价：
- 显存占用增加 4 倍
  - 训练和推理速度下降
  - 需要更大的 GPU

# 4.7 损失函数改进

## 4.7.1 尺度感知损失

# 标准损失对所有尺度目标一视同仁  
# 尺度感知损失为小目标赋予更大权重

```
def scale_aware_loss(pred, target, bbox):  
    area = (bbox[:, 2] - bbox[:, 0]) * (bbox[:, 3] - bbox[:, 1])  
    # 小目标面积小 → 权重大  
    weight = 1.0 / (area + 1.0) ** 0.5  
    weight = weight / weight.mean() # 归一化  
  
    loss = F.binary_cross_entropy(pred, target, reduction='none')  
    return (loss * weight).mean()
```

## 4.7.2 IoU 损失改进

标准 IoU 对小目标的定位偏差极为敏感（1 像素偏移可能导致 IoU 大幅下降）。

| IoU 变体 | 改进点      | 对小目标的帮助    |
|--------|----------|------------|
| GIoU   | 引入最小包围框  | 缓解无重叠时梯度为零 |
| DIoU   | 考虑中心点距离  | 加速收敛       |
| CIoU   | + 宽高比一致性 | 更精确定位      |

| IoU 变体    | 改进点     | 对小目标的帮助   |
|-----------|---------|-----------|
| Wise-IoU  | 动态聚焦机制  | 减少低质量样本干扰 |
| Inner-IoU | 辅助边界框计算 | 小目标定位更稳定  |

## 4.8 局部训练策略 (Local Training)

2026 年提出的**局部训练 (LT)** 策略：

核心思想：添加仅训练时生效的辅助分支，专门聚焦小目标

主分支：正常检测流程

辅助分支：仅在小目标区域计算额外梯度，强化小目标学习

推理时：

- 辅助分支被移除
- 零额外推理开销
- 但模型已获得更好的小目标检测能力

效果：AP<sub>S</sub> 提升 2~5%，无推理速度损失

## 4.9 姿态估计辅助训练

创新思路（2025-2026）：

用 YOLOv8 姿态估计作为辅助任务

- 预测关键点与 GT 框中心的距离作为额外训练目标
- 迫使模型更精确地定位目标中心

效果：小目标 mAP 提升 > 10%，无额外推理开销

# 4.10 后处理优化

## 4.10.1 Soft-NMS

标准 NMS：IoU > 阈值的框直接删除  
→ 问题：密集小目标可能被误删

Soft-NMS：  
 $score\_new = score\_old \times f(IoU)$

线性衰减： $f(IoU) = 1 - IoU$ , if  $IoU > threshold$   
高斯衰减： $f(IoU) = \exp(-IoU^2 / \sigma)$

→ 不直接删除，而是降低重叠框的分数  
→ 密集小目标保留更好

## 4.10.2 类别感知 NMS

每个类别独立做 NMS  
→ 避免不同类别的高分框互相抑制  
→ 对小目标类别的召回率更友好

# 5. 主流数据集与基准

## 5.1 通用数据集

| 数据集     | 规模              | 小目标占比    | 特点        |
|---------|-----------------|----------|-----------|
| MS COCO | 33 万图 / 250 万实例 | ~41% 小目标 | 通用标准基准    |
| SODA-D  | 2,500 图         | 专用于小目标   | 小目标检测专用基准 |

## 5.2 航拍 / UAV 数据集

| 数据集      | 场景    | 目标类型            | 特点         |
|----------|-------|-----------------|------------|
| VisDrone | 无人机航拍 | 行人/车辆/自行车等 10 类 | 极端小目标，密集场景 |

| 数据集   | 场景    | 目标类型           | 特点       |
|-------|-------|----------------|----------|
| UAVDT | 无人机航拍 | 车辆             | 含高度/密度标注 |
| DOTA  | 卫星遥感  | 建筑/车辆/舰船等 15 类 | 旋转框标注    |
| xView | 卫星遥感  | 60 类           | 高分辨率卫星图像 |
| DIOR  | 遥感    | 20 类           | 多尺度遥感目标  |

### 5.3 特殊领域数据集

| 数据集          | 领域   | 目标 | 特点          |
|--------------|------|----|-------------|
| TinyPerson   | 安防监控 | 人物 | 目标高度 < 20px |
| CVC-ClinicDB | 医学   | 息肉 | 内窥镜图像       |
| Crack500     | 工业   | 裂缝 | 混凝土表面裂缝     |


## 6. 性能对比

### 6.1 SOTA 模型在 COCO 上的表现

| 模型             | Backbone    | 输入尺寸 | AP_S (%) | mAP (%) | 参数量 (M) | GFLOPs | FPS |
|----------------|-------------|------|----------|---------|---------|--------|-----|
| SOD-YOLOv8     | CSPDarknet  | 640  | 33.2     | 53.8    | 44.1    | 168.1  | 118 |
| MGA-Net        | ResNet-50   | 640  | 30.1     | 51.2    | 28.5    | 98     | 95  |
| Improved-DETR  | ResNet-50   | 800  | 29.5     | 48.9    | 41.5    | 86     | 32  |
| AUHF-DETR      | MobileNetV3 | 1280 | 28.9     | 49.5    | 5.8     | 8.9    | 68  |
| ESOD-RetinaNet | ResNet-101  | 1200 | 25.6     | 43.1    | 44.6    | 239    | 15  |



## 6.2 方法选择决策树



## 6.3 推荐组合方案

### 方案 A：实时航拍小目标检测

数据: SAHI 切片训练 + Copy-Paste 增强 + Mosaic  
网络: YOLOv8 + P2 检测头 + BiFPN + SE 注意力  
训练: 1280×1280 分辨率 + 局部训练(LT)策略  
损失: Focal Loss (分类) + Wise-IoU (回归)  
后处理: Soft-NMS  
性能预期: AP\_S ~30-35%, FPS > 60

## 方案 B：高精度医学/工业检测

数据：高分辨率采集 + 专业增强 + 生成式扩充

网络：DETR 系列 + 多尺度边缘增强 + 超分辨率预处理

训练：两阶段训练 + 课程学习

损失：尺度感知损失 + GIoU

后处理：类别级阈值优化

性能预期：AP\_S ~35-40%，FPS ~15-30

## 方案 C：边缘端轻量部署

数据：SAHI 切片 + 轻度增强

网络：AUHF-DETR (MobileNetV3 backbone)

训练：知识蒸馏（大模型为教师）

部署：INT8 量化 + TensorRT 加速

性能预期：AP\_S ~25-30%，FPS > 60, < 10M 参数

# 7. 未来发展方向

## 7.1 基础视觉大模型

SAM (Segment Anything) / DINOv2 等基础模型

- 在海量数据上预训练，具备强大的通用视觉理解能力
- 通过少量微调迁移到小目标检测
- CVPR 2025 已设立 Foundation Few-Shot Object Detection 竞赛

潜力：

- 减少对标注数据的依赖
- 跨域迁移能力更强
- 对小目标的泛化能力可能优于从头训练的专用模型

## 7.2 生成式 AI 辅助

扩散模型在小目标检测中的应用：

1. 合成数据生成
  - 用扩散模型生成大量小目标训练样本
  - AeroGen (CVPR 2025) 已在遥感领域验证
  - 解决小目标数据稀缺的根本问题
2. 超分辨率增强
  - 扩散模型恢复小目标的高频细节
  - 比传统 GAN 超分质量更高
3. 特征增强
  - 在特征空间用生成模型补全信息
  - 端到端联合训练

## 7.3 Mamba / 状态空间模型 (SSM)

Mamba 的优势：

- 线性时间复杂度  $O(N)$  (Transformer 为  $O(N^2)$ )
- 保持全局上下文建模能力
- 适合处理高分辨率图像 (小目标检测必需)

潜在应用：

- 替代 Transformer 作为检测器的 backbone/neck
- 在保持精度的同时降低计算开销
- 使高分辨率推理更加可行

现状 (2025-2026)：早期探索阶段，已在分类/分割任务中展现潜力

## 7.4 统一空频域建模

新方向：同时在空间域和频率域分析

空间域：捕获纹理、形状等局部信息

频率域：捕获全局结构、周期性模式

方法：

- 小波变换卷积 (Wavelet Convolution)
- 频域注意力机制
- 双域特征融合

SOD-YOLOv8 已采用此思路，AP<sub>S</sub> 达到 33.2%

## 7.5 多模态融合

融合多种传感器数据：

RGB + 红外 (IR) → 夜间/恶劣天气检测

RGB + 深度 (Depth) → 距离感知辅助

RGB + 热成像 → 温差区分目标与背景

可见光 + SAR → 全天候遥感检测

优势：

- 弥补单一模态的信息不足
- 对小目标在不同条件下的鲁棒性更强

## 7.6 自监督与少样本学习

目标：减少对像素级标注的依赖

方法：

1. 自监督预训练
  - 在大量无标注图像上学习通用视觉表示
  - MAE / DINO / SimCLR 等范式
2. 少样本迁移
  - 仅需少量小目标标注即可适配新场景
  - 原型网络 / 元学习思路
3. 弱监督学习
  - 用图像级标注代替框级标注
  - 降低标注成本

## 7.7 端到端实时部署

挑战：小目标检测的高分辨率需求 vs 边缘设备的算力限制

趋势：

- 知识蒸馏：大模型 → 小模型，保留小目标检测能力
- 神经架构搜索 (NAS)：自动搜索最优的小目标检测架构
- 模型压缩：剪枝 + 量化 + 蒸馏联合优化
- 专用硬件加速：NPU / FPGA 针对小目标检测优化

目标：在 < 10W 功耗下实现实时小目标检测

# 7.8 未来发展方向时间线

2025-2026（当前）：

- ✅ FPN 改进 + 注意力机制 + YOLO 系列
- ✅ SAHI 切片推理
- ✅ 生成式数据增强

2026-2027（近期）：

- 🌐 基础模型（SAM/DINOv2）在 SOD 中的广泛迁移
- 🌐 Mamba/SSM 替代 Transformer
- 🌐 统一空频域建模成熟

2027+（远期）：

- 🌟 多模态融合成为标配
- 🌟 自监督 + 少样本消除标注瓶颈
- 🌟 端侧实时高精度小目标检测
- 🌟 通用小目标基础模型

# 8. 参考文献索引

## 综述论文

| 论文                                                                       | 会议/期刊                                 | 年份   | 重点                      |
|--------------------------------------------------------------------------|---------------------------------------|------|-------------------------|
| Aldubaikhi & Patel, "Advancements in Small-Object Detection (2023-2025)" | MDPI Applied Sciences                 | 2025 | PRISMA 综述，112 篇论文，含定量对比 |
| Nikouei et al., "Small Object Detection: A Comprehensive Survey"         | Intelligent Systems with Applications | 2025 | 挑战、技术与应用全景              |
| "A Survey of SOD Based on Deep Learning in Aerial Images"                | Springer AI Review                    | 2025 | 航拍/遥感专题                 |
| "A Decade of Research in Small Object Detection"                         | Springer Nature                       | 2025 | 十年回顾                    |

# 关键方法论文

| 论文                                                  | 会议                  | 贡献                     |
|-----------------------------------------------------|---------------------|------------------------|
| Lin et al., "Focal Loss for Dense Object Detection" | ICCV 2017           | Focal Loss + RetinaNet |
| Tan et al., "EfficientDet"                          | CVPR 2020           | BiFPN 加权特征融合           |
| Zhang et al., "ATSS"                                | CVPR 2020           | 自适应标签分配                |
| Ge et al., "OTA"                                    | CVPR 2021           | 最优传输标签分配               |
| Ge et al., "YOLOX"                                  | 2021                | SimOTA + Anchor-Free   |
| "HSF-DETR"                                          | 2024                | 多视角上下文 DETR            |
| "SOD-YOLOv8"                                        | 2024                | 空频统一建模，AP_S 33.2%      |
| "AUHF-DETR"                                         | 2024                | 5.8M 参数轻量 Transformer  |
| "AeroGen"                                           | CVPR 2025           | 扩散模型生成遥感数据             |
| "Enhanced YOLOv11n"                                 | Nature Sci. Reports | 2026                   |
| "Local Training for YOLO"                           | ScienceDirect       | 2026                   |

# 框架与工具

| 名称                 | 链接                                                                                              | 用途          |
|--------------------|-------------------------------------------------------------------------------------------------|-------------|
| SAHI               | <a href="https://github.com/obss/sahi">github.com/obss/sahi</a>                                 | 切片辅助推理框架    |
| Ultralytics YOLOv8 | <a href="https://github.com/ultralytics/ultralytics">github.com/ultralytics/ultralytics</a>     | YOLO 系列官方实现 |
| VisDrone Dataset   | <a href="https://github.com/VisDrone/VisDrone-Dataset">github.com/VisDrone/VisDrone-Dataset</a> | UAV 检测基准    |
| TinyBenchmark      | <a href="https://github.com/ucas-vg/TinyBenchmark">github.com/ucas-vg/TinyBenchmark</a>         | 极小目标基准      |